DESCRIPCIÓN DEL DATASET: SISTEMA DE RUTAS TRANSMILENIO

APRENDIZAJE AUTOMÁTICO — ÁRBOL DE DECISIÓN

JULIANA ESTHER NARANJO CAMACHO

CORPORACION UNVERSITARIA IBEROAMERICANA

FACULTAD DE INGENIERIA

ING. SANDRA BAUTISTA

BOGOTÁ 10 OCTUBRE 2026

1. Descripción General del Dataset

El dataset fue desarrollado como fuente de datos para el entrenamiento de un modelo de aprendizaje automático basado en árbol de decisión, con el objetivo de clasificar rutas del sistema de transporte masivo TransMilenio de Bogotá según su duración estimada. La generación de datos irreales se justifica dado que TransMilenio no publica abiertamente datos históricos de tiempos de viaje por ruta y estación con el nivel de detalle requerido para este ejercicio.

Los registros fueron generados a partir del grafo de conocimiento construido en la actividad anterior (sistema A*), respetando las conexiones reales entre estaciones, los tiempos promedio entre troncales y los factores de variación por hora y día de la semana. Se generaron 403 registros con semilla aleatoria fija (seed=42) para garantizar reproducibilidad.

2. Origen y Fuentes de Referencia

El dataset integra información de tres fuentes:

- **Base de conocimiento propia:** Grafo de estaciones y conexiones desarrollado en la actividad anterior, con 36 estaciones en 4 troncales (Caracas, Américas, Calle 80 y Suba) y 34 reglas de conexión.
- **Datos operativos de referencia:** TransMilenio S.A. (2023). Informe de operación y estadísticas del sistema. Recuperado de https://www.transmilenio.gov.co — tiempos promedio entre estaciones y frecuencias por período horario.
- **Factores de variación horaria:** DANE (2022). Encuesta de Movilidad Bogotá. Distribución de viajes por período horario y día de la semana en Bogotá.

3. Estructura del Dataset

El archivo dataset_transmilenio.csv contiene 403 registros y 12 columnas. La siguiente tabla describe cada variable:

Variable	Tipo	Valores / Rango	Descripción
id	Entero	1 – 403	Identificador único del

			registro
estacion_origen	Categórica	36 estaciones	Nombre de la estación de origen
troncal_origen	Categórica	Caracas/Americas/Calle80/Suba	Troncal de la estación de origen
estacion_destino	Categórica	36 estaciones	Nombre de la estación de destino
troncal_destino	Categórica	Caracas/Americas/Calle80/Suba	Troncal de la estación de destino
hora_periodo	Entero	0 – 5	0=Madrugada, 1=Mañana pico, 2=Mañana normal, 3=Tarde normal, 4=Tarde pico, 5=Noche
dia_tipo	Entero	0 – 2	0=Hábil, 1=Sábado, 2=Domingo/Festivo
num_estaciones	Entero	2 – 22	Número de estaciones en la ruta calculada
num_transbordos	Entero	0 – 1	Número de transbordos requeridos
tiempo_minutos	Decimal	3.0 – 98.5	Tiempo estimado de viaje en minutos
categoria_ruta	Entero	0=Rápida, 1=Media, 2=Larga	Variable objetivo (target) del modelo
categoria_nombre	Categórica	Rápida/Media/Larga	Etiqueta textual de la categoría

4. Estadísticas Descriptivas

Variable objetivo — distribución de clases:

Categoría	Registros	Porcentaje
Rápida (0)	96	23.8%
Media (1)	253	62.8%
Larga (2)	54	13.4%

Variables numéricas — rango y promedio:

Variable	Mínimo	Máximo	Promedio
num_estaciones	2	22	10.5
num_transbordos	0	1	0.57
tiempo_minutos	3.0	98.5	37.2

Referencias

DANE. (2022). Encuesta de Movilidad Bogotá 2021. Departamento Administrativo Nacional de Estadística.

Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España.

TransMilenio S.A. (2023). Informe estadístico de operación del sistema. https://www.transmilenio.gov.co