MODELO DE ÁRBOL DE DECISIÓN

SISTEMA DE CLASIFICACIÓN DE RUTAS TRANSMILENIO

JULIANA ESTHER NARANJO CAMACHO

CORPORACION UNVERSITARIA IBEROAMERICANA

FACULTAD DE INGENIERIA

ING. SANDRA BAUTISTA

BOGOTÁ 10 OCTUBRE 2026

1. Descripción del Modelo

Se implementó un clasificador basado en árbol de decisión CART (Classification and Regression Trees) utilizando la librería scikit-learn de Python. El algoritmo emplea el criterio de impureza de Gini para seleccionar las variables de división en cada nodo, tal como lo describe Palma Méndez (2008) en el Capítulo 17.

Hiperparámetros configurados:

Parámetro	Valor	Justificación
criterion	gini	Criterio de impureza para la selección de divisiones (CART)
max_depth	5	Profundidad máxima del árbol para evitar sobreajuste
min_samples_split	10	Mínimo de muestras para dividir un nodo interno
min_samples_leaf	5	Mínimo de muestras requeridas en una hoja
random_state	42	Semilla para reproducibilidad de resultados

2. Configuración de Pruebas

División de datos: 70% entrenamiento (282 muestras) / 30% prueba (121 muestras), con estratificación por clase para mantener la distribución original. Se realizó además validación cruzada de 5 pliegues (k=5) sobre el conjunto completo.

3. Resultados de Exactitud

Métrica	Valor	Observación
Accuracy entrenamiento	89.01%	Indica buen aprendizaje de los patrones del dataset
Accuracy prueba	85.95%	Diferencia de ~3% indica buen balance sin sobreajuste significativo
Validación cruzada (5k)	85.37% ± 2.33%	Confirma estabilidad del modelo en distintas particiones

4. Reporte de Clasificación por Clase

Clase	Precisión	Recall	F1-Score	Soporte
Rápida (0)	0.73	0.93	0.82	29
Media (1)	0.94	0.83	0.88	76
Larga (2)	0.82	0.88	0.85	16

5. Importancia de Variables

El árbol identificó las siguientes variables como más relevantes:

Variable	Importancia Gini	Interpretación
N° Transbordos	56.25%	Variable más determinante: un transbordo incrementa significativamente el tiempo
Hora Período	25.62%	El horario pico aumenta el tiempo en hasta un 35%
Día Tipo	10.14%	Los fines de semana tienen menor congestión
N° Estaciones	7.99%	A mayor número de estaciones, mayor tiempo base de viaje
Troncal Origen	0.00%	No aportó poder discriminativo adicional tras otras variables
Troncal Destino	0.00%	No aportó poder discriminativo adicional tras otras variables

6. Casos de Prueba Manuales

ID	Descripción	Entradas	Esperado	Obtenido	Estado
CP-01	Portal Norte → Portal Sur, sin transbordo, hora normal	Troncal O=Caracas, D=Caracas, hora=2, día=0, estaciones=14, transbordos=0	Rápida	Rápida (80.0%)	✓ Correcto
CP-02	Portal Americas → Portal Norte, 1 transbordo, hora pico	Troncal O=Americas, D=Caracas, hora=1, día=0, estaciones=16, transbordos=1	Larga	Larga (88.2%)	✓ Correcto
CP-03	Portal 80 → Ricaurte, 1 transbordo, sábado	Troncal O=Calle80, D=Americas, hora=3, día=1, estaciones=12, transbordos=1	Media	Media (91.5%)	✓ Correcto
CP-04	Pepe Sierra → Calle 26, mismo día festivo	Troncal O=Suba, D=Caracas, hora=2, día=2, estaciones=8, transbordos=1	Media	Media (84.3%)	✓ Correcto

7. Conclusión de Pruebas

El modelo de árbol de decisión alcanzó una exactitud del 85.95% en el conjunto de prueba y 85.37% en validación cruzada, lo que demuestra una capacidad de generalización satisfactoria. La variable más determinante fue el número de transbordos, seguida del período horario, lo que concuerda con el comportamiento real del sistema TransMilenio. Los cuatro casos de prueba manual resultaron correctamente clasificados, validando la coherencia del modelo con el conocimiento del dominio.

Referencias

Palma Méndez, J. T. (2008). Inteligencia artificial: métodos, técnicas y aplicaciones. McGraw-Hill España.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825–2830.